

Оптимизация

$$f(x) \rightarrow \min_x$$

$$f'(x) = 0 \Rightarrow x^*$$

$$f''(x) \quad f''(x^*) > 0$$

$$f(x_1, \dots, x_n) \rightarrow \min_x$$

$$\nabla_x f = 0 \Rightarrow x^*$$


$$\nabla_{xx}^2 f = H$$

$H > 0$ min

$H < 0$ max

$H \approx 0$ сегментальна

Критерий Сильвестра



$$\begin{aligned} \Delta_1 &> 0 & \Delta_1 &> 0 \\ \Delta_2 &> 0 & \Delta_2 &< 0 \\ \Delta_3 &> 0 & \Delta_3 &> 0 \\ \dots & \dots & \dots & \dots \end{aligned}$$

min max

$$\begin{cases} f(x) \rightarrow \min_x \\ h(x) = 0 \\ x = h^{-1}(0) \\ f(h^{-1}(0)) \rightarrow \min_a \end{cases}$$


Максимизация

$$\begin{cases} f(x) \rightarrow \min_{x \in \mathbb{R}^d} \\ g_i(x) \leq 0 \quad i = 1, \dots, m \\ h_j(x) = 0 \quad j = 1, \dots, p \end{cases}$$

$$I_f(z) = \begin{cases} 0 & z \leq 0 \\ \infty & z > 0 \end{cases} \quad \lambda \cdot z$$

$$I_o(z) = \begin{cases} 0, & z = 0 \\ \infty, & z \neq 0 \end{cases} \quad \mu \cdot z$$

$$f(x) + \sum_{i=1}^m I_f(g_i(x)) + \sum_{j=1}^p I_o(h_j(x)) \rightarrow \min_x$$



$$[M_i > 0]$$

$$L(y_i, a(x_i)) = [y_i = a(x_i)]$$

$$y_i \in \{-1, 1\} \quad a(x_i) - \text{модель}$$

$$M_i = y_i \cdot a(x_i)$$




$$\text{Max}(1-M_i, 0)$$

SVM

$$y_i \ln P_i + (-y_i) \ln (1-P_i) \quad \{0, 1\}$$

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x) \rightarrow \min_x$$



! $\lambda_i \geq 0$

Двойственная фнкц.
даёт оценку на
минимум исх.
функции

Двойственные функции

x - primary переменные (primary)

λ, μ - двойственные переменных (dual)

$g(\lambda, \mu) = \inf_x L(x, \mu, \lambda)$ - двойственная фнкц.

→ всегда возрастает

→ может при некоторых λ, μ равняться $-\infty$

мотивация:

курсы по
оптим.

- теория двойственности
- алгоритмы
- когда работает

SGD:

$$w_t = w_{t-1} - \eta_t \nabla_w L(w_{t-1})$$

- Если фнкц. выпуклая
- Линейность градиента
- Условие Родбенса-Монро

$$\sum_{k=1}^{\infty} \eta_k = \infty \quad \sum_{k=1}^{\infty} \eta_k^2 < \infty$$



\Rightarrow работает

DL: У нас все предыдущие нарушение, то мы всё равно используем SGD

\Rightarrow специальные

Пример $\frac{n}{d} \rightarrow \infty$ ММП
 $d \gg n$

- решётка рисунок
- фиксирована
- аугментация



x' - допустимая точка $g_i(x') \leq 0 \quad h_j(x') = 0$

$$L(x', \lambda, \mu) = f(x') + \sum_{i=1}^m \lambda_i g_i(x') + \sum_{j=1}^p \mu_j h_j(x')$$


≥ 0 ≤ 0 $\stackrel{!}{\leq}$

$$\inf_{x'} L(x', \lambda, \mu) \leq \inf_{x'} f(x') = f(x^*)$$

решение задачи

$$\inf_x L(x, \lambda, \mu) = g(\lambda, \mu)$$


$$\Rightarrow g(\lambda, \mu) \leq f(x^*)$$



Как приблизить $g(\lambda, \mu)$ к $f(x^*)$?

$$\begin{cases} g(\lambda, \mu) \rightarrow \max_{\lambda, \mu} \\ \lambda_i \geq 0 \end{cases}$$

Двойственная задача - наиск
самой хорошей точкой
огранич



x^* - решение первой задачи

λ^*, μ^* - решения 2-й задачи

$$g(\lambda^*, \mu^*) \leq f(x^*)$$

Следует из условия оптимальности
(условие Сенгера)

Информация

$$\begin{cases} \frac{1}{2} \|x\|_2^2 = \frac{1}{2} x^T x \rightarrow \min_x \\ Ax = b \\ dL = \nabla L^T \perp x \end{cases}$$

$$L(x, \mu) = \frac{1}{2} x^T x + \mu^T (Ax - b)$$

$$dL = \frac{1}{2} d(x^T \cdot x) + \frac{1}{2} x^T \cdot dx + \mu^T A dx = (x^T + \mu^T A) dx$$

$[1 \times 1]$

$$S_{xx} \quad S^T = S$$

$$\frac{\partial L}{\partial x} = x + A^T \mu = 0$$

$$x^* = -A^T \mu$$

$$g(\mu) = \inf_x L(x, \mu) = \frac{1}{2} (A^T \mu)^T A^T \mu + \mu^T (-A A^T \mu - b) =$$

$\mu^T A A^T \mu$

$$= -\frac{1}{2} \mu^T A A^T \mu - \mu^T b \rightarrow \max_{\mu}$$

Задача: μ^* - ? $g(\mu^*) \leq f(x^*)$ - Правильна ли это?

Упрощение

$$\begin{cases} c^T x \rightarrow \min_x \\ Ax = b \\ x_j \geq 0 \quad \forall j \\ -x_j \leq 0 \end{cases}$$

р. линейная

$$L(x, \lambda, \mu) = c^T x - \lambda^T (x - 0) + \mu^T (Ax - b)$$

$$dL = c^T dx - \lambda^T d(x - 0) + \mu^T A dx$$

$$c - \lambda + A^T \mu = 0 \quad \text{---}$$

$$L(x, \lambda, \mu) = (c - \lambda + A^T \mu)^T x - \mu^T b \rightarrow \min_x$$

$$c - \lambda + A^T \mu = 0 \quad \inf_x L(x, \lambda, \mu) = -\mu^T b$$


$$\neq 0 \quad x \rightarrow -\infty$$

$$g(\lambda, \mu) = \begin{cases} -\mu^T b, & c - \lambda + A^T \mu = 0 \\ -\infty & c - \lambda + A^T \mu \neq 0 \end{cases}$$


Для минимума $g(\lambda, \mu) \rightarrow \max_{\lambda, \mu} \Rightarrow$ ВТОРАЯ СТРУКТУРА
отвечающая

$$\begin{cases} -\mu^T b \rightarrow \max_{\lambda, \mu} \\ c - \lambda + A^T \mu = 0 \\ \lambda \geq 0 \end{cases}$$


Двойная структура задачи.



бұнықа



төр бұнықа



$$t x_1 + (1-t) x_2$$

$$f(t x_1 + (1-t) x_2) \leq t f(x_1) + (1-t) f(x_2)$$

$t \in (0, 1)$

бұнықа бірнеше

Ұсноғыл Карош - Күнна - Текер

1939

1951

жылдар

Символ әдебиеттегі оғын $g(x^*, \lambda^*) = f(x^*)$

Ұсноғыл Слейтер:

① Видуктал оңт. жағажақ

② \exists допустима торка x' : $g_i(x') < 0$

Внутренний допустима торка

Достаточное
условие
символ
әдебиеттегі
важливості

$$f(x^*) = g(x^*, \lambda^*) = \inf_x [f(x) + \sum_i \lambda_i^* g_i(x) + \sum_j \mu_j^* h_j(x)]$$

$$\leq f(x^*) + \boxed{\sum_i \lambda_i^* g_i(x^*)} + \boxed{\sum_j \mu_j^* h_j(x^*)} \leq f(x^*)$$

$$\leq 0 \quad = 0$$

$\equiv 0$

1) Есле розв'язок при цьому зображені

$$L(x^*, \lambda^*, \mu^*) \rightarrow \min_x \Rightarrow x^*$$

$$2) \begin{cases} \lambda_i^* g_i(x^*) = 0 \\ \geq 0 \quad \leq 0 \end{cases} \quad \lambda_i^* g_i(x^*) = 0 \quad \forall i$$

Умови економічності
нечисельності

III. (Каросна - Кука - Талера)

Пусть x^* - розв'язок ірвінгії зображені, тоді

$\exists \mu^*, \lambda^*$:

$$\left\{ \begin{array}{l} \nabla_x L(x^*, \lambda^*, \mu^*) = 0 \\ g_i(x^*) \leq 0 \quad \forall i \\ h_j(x^*) = 0 \quad \forall j \\ \lambda_i^* \geq 0 \quad \forall i \\ \lambda_i^* g_i(x^*) = 0 \quad \forall i \end{array} \right.$$

- Необхідність
- зокрема виконання
- Достаточність
- задачі

Задачі

$$\left\{ \begin{array}{l} (x-4)^2 + (y-4)^2 \rightarrow \min_{x,y} \\ x+y \leq 4 \quad y \leq 4-x \\ x+3y \leq 9 \quad y \leq 3 - \frac{1}{3}x \end{array} \right.$$

$$L = (x-4)^2 + (y-4)^2 + \lambda_1(x+y-4) + \lambda_2(x+3y-8)$$

$$\begin{cases} 2(x-4) + \lambda_1 + \lambda_2 = 0 \\ 2(y-4) + \lambda_1 + 3\lambda_2 = 0 \\ x+y \leq 4 \quad \lambda_1 \geq 0 \\ x+3y \leq 9 \quad \lambda_2 \geq 0 \end{cases} \quad \nabla L = 0$$

$\lambda_1(x+y-4) = 0$
 $\lambda_2(x+3y-8) = 0$

Pemecahan (4 canggah)

- $x+y-4=0 \quad x+3y=9 \quad \lambda_1 > 0 \quad \lambda_2 > 0$

$$\begin{cases} x+y=4 \\ x+3y=9 \end{cases}$$

$$\begin{cases} 2(\frac{3}{2}-4) + \lambda_1 + \lambda_2 = 5 \\ 2(\frac{5}{2}-4) + \lambda_1 + 3\lambda_2 = 3 \end{cases}$$

$$x+3(4-x)=9$$

$$-2\lambda_2 = 2$$

$$x=\frac{3}{2}, \quad y=\frac{5}{2}$$

$$\lambda_2 = -1$$


$$\lambda_2 > 0$$



- $x+y=4$
 $x+3y < 9$
 $\lambda_1 > 0$
 $\lambda_2 = 0$

$$\begin{cases} 2(x-4) + \lambda_1 = 0 \\ 2(y-4) + \lambda_1 = 0 \\ x+y = 4 \end{cases}$$

$x=y=2$
 $\lambda_1 = 4$



$$x+3y < 9$$

$$2+6=8 < 9$$



- Octahedron 2 canggah dapat

Итеративные методы


$$\begin{cases} f(x) \rightarrow \min_{x \in \mathbb{R}^n} \\ g_i(x) \leq 0 \quad i=1, \dots, m \\ h_j(x) = 0 \quad j=1, \dots, p \end{cases}$$

Но всегда хотят то как
это можно решить
=> iterative methods
 $(x_k)_{k=1}^{\infty}$

Oracle conception



Гиперплоскость



$$\begin{cases} f(x) \rightarrow \min_{x \in \mathbb{R}^n} \\ x \in B^n \\ B^n = \{x \in \mathbb{R}^n \mid 0 \leq x_i \leq 1 \forall i\} \end{cases}$$

Числ: найти оптимальное
 x^* (не смотря)

максимум \tilde{x}

Степени свободы

$(p+1)^n$ вариантов

$$|f(\tilde{x}) - f(x^*)| \leq \epsilon$$


$$\|\tilde{x} - x^*\|_\infty \leq \frac{1}{2P}$$

$$|f(\tilde{x}) - f(x^*)| < ?$$

Для оценки этого расстояния
на f налагиваются ограничения.

Линейные функции

$$|f(x) - f(y)| \leq L \cdot \|x - y\|_\infty$$




формула Липситца:

$$\|x\|_p = \sqrt[p]{\sum_i |x_i|^p}$$

$p=1$ математическая
форма

$$\sum_i |x_i|$$



$$\sqrt{\sum_i x_i^2}$$


$p=2$ евклидова форма



$$p=\infty$$

$$\max_i |x_i|$$

$$\max(1, 2) = 2$$



$$|f(\tilde{x}) - f(x^*)| \leq L \cdot \|x - y\|_\infty \leq \frac{L}{2P} = \epsilon$$

$$P = \frac{L}{2\epsilon}$$

$$P+1 = \frac{L}{2\epsilon} + \underline{\lambda}$$

$$(P+1)^n = \left(\frac{L}{2\epsilon} + \underline{\lambda}\right)^n$$

$$n=2 \quad \times \quad \text{learning rate}$$

$$\epsilon=1 \quad 4 \quad \text{вариант}$$

$$L=2 \quad \text{оп. может}$$

расчете начинаться не sooner
чем в два раза

K-NN-BD
непрерывная
го однином


$$\varepsilon = 0.01 \quad 10^2 > 10000$$

Градиентный спуск

$f(x)$ - знакал т.е. градиент линейный

$$Q(w) = \sum (y_i - x_i^T w)^2 + \|w\|_2^2$$

$$\rightarrow \min_w$$



init: w^0

$$w^t = w^{t-1} - \eta_t \cdot \nabla_w Q(w^{t-1})$$


Gradient Descent

Направление градиента - направл. наиск. убывания

$$x_0 + \lambda \cdot d \quad \|d\| \leq 1 \quad \lambda \in \mathbb{R}$$

$$x' = x_0 + \lambda \cdot d$$

$$x' - x_0 = \lambda \cdot d$$



$$f(x') < f(x_0)$$

$$f(x') \approx f(x_0) + \nabla^T f(x_0) \cdot (x' - x_0)$$

$$\cancel{f(x_0) + \nabla^T f(x_0) (x' - x_0)} < \cancel{f(x_0)}$$

$$\lambda \cdot d$$

$$\nabla^T f(x_0) \cdot \lambda \cdot d < 0 \quad 1 : \lambda$$

$$\nabla^T f(x_0) \cdot d < 0$$

$$f(x') \rightarrow \min_d$$

$$f(x_0) + \nabla^T f(x_0) \cdot \lambda \cdot d \rightarrow \min_d$$

$$\nabla^T f(x_0) \cdot \cancel{\lambda \cdot d} \rightarrow \min_d \quad \|d\|^2 = 1$$

$$L = \nabla^T f(x_0) \cdot d + \lambda \cdot (d^T d - 1)$$

$$\frac{\partial L}{\partial d} = \nabla f(x_0) + 2\lambda d = 0 \Rightarrow d = -\frac{1}{2\lambda} \cdot \nabla f(x_0)$$

$$\|d\|^2 = \frac{1}{4\lambda^2} \cdot \|\nabla f(x_0)\|^2 = 1$$

$$\frac{1}{2\lambda} = \frac{1}{\|\nabla f(x_0)\|}$$

$$d = -\frac{\nabla f(x_0)}{\|\nabla f(x_0)\|}$$

$$x^{t+1} = x^t - \frac{\lambda}{\|\nabla f(x_0)\|} \cdot \nabla f(x^t)$$

x'

n

Hyperparameter

$$Q(w) = \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top w)^2 \rightarrow \min_w$$

$$\nabla_w Q = -2 \cdot \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top w) x_i$$

$$w^t = w^{t-1} - 0.01 \cdot \left(-2 \cdot \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top w^t) x_i \right)$$

h Sonderfall
 \Rightarrow geringe Varianz


SGD

$1, \dots, n$ shuffle

$$\hat{\nabla}_w Q = -2 \cdot (y_i - x_i^\top w) x_i$$

learning rate

$$w^t = w^{t-1} - 0.01 \cdot (-2 \cdot (y_i - x_i^\top w^t) x_i)$$




Mini-Batch SGD

$1, 2, 3, \dots, n$ shuffle

$m \quad m \quad \dots \quad m$

$$\sum_{i=1}^m$$

$m \ll n$



lr - HaGo
ногопатъ

$$(y_i - x_i^T w)$$

модификации:

$$Q(w) = \frac{1}{n} \sum L(w, x_i, y_i)$$

① Momentum

$$g_t = \frac{1}{m} \sum_{i=1}^m \nabla_w L(w^{t-1}, x_i, y_i)$$

$$w_t = w_{t-1} - \eta \cdot g_t$$

$$h_t = \lambda \cdot h_{t-1} + \eta \cdot g_t$$

$$w_t = w_{t-1} - h_t$$


методистарт

$$w_{t-1} - \lambda h_{t-1} - \eta g_t$$

② Nesterov Momentum

$$h_t = \lambda \cdot h_{t-1} + \eta \cdot \nabla_w L(w_{t-1} - \lambda h_{t-1})$$

$$w_t = w_{t-1} - h_t$$



③ RMSprop / Adagrad

$$g_t = \frac{1}{m} \sum_{i=1}^m \nabla_w L(w^{t-1})$$

сумма разниц



$$\begin{aligned} w_t &= w_{t-1} - \eta \cdot g_t \\ &\quad - \eta \cdot \mathbb{E}[g_t] \end{aligned}$$

$$\theta \hat{\theta} \mathbb{E}(\hat{\theta}) = \theta$$

$$\text{Var}(\hat{\theta})$$

$$\text{Var}(g_t) = \mathbb{E}(g_t^2) - \mathbb{E}(g_t)^2$$

$$g_t^2$$

$$G_t^j = G_{t-1}^j + (g_t^j)^2$$

$$w_t^j = w_{t-1}^j - \frac{\eta}{\sqrt{G_t^j + 10^{-6}}} \cdot g_t^j$$

Adagrad

RMSprop

$$G_t^j = \gamma G_{t-1}^j + (1-\gamma)(g_t^j)^2$$

$$w_t^j = w_{t-1}^j - \frac{\eta}{\sqrt{G_t^j + 10^{-6}}} \cdot g_t^j$$

④ Adam

$$h_t^j = \frac{\beta_1 h_{t-1}^j + (1-\beta_1) g_t^j}{1-(\beta_1)^t}$$

$$G_t^j = \frac{\beta_2 G_{t-1}^j + (1-\beta_2) (g_t^j)^2}{1-(\beta_2)^t}$$

$$w_t^j = w_{t-1}^j - \frac{n_t}{\sqrt{G_t^j + 10^{-5}}} \cdot h_t^j$$

Ada Belief

$$h_t^j = \frac{\beta_1 h_{t-1}^j + (1-\beta_1) g_t^j}{1-(\beta_1)^t}$$

$$G_t^j = \frac{\beta_2 G_{t-1}^j + (1-\beta_2) (g_t^j - h_t^j)^2}{1-(\beta_2)^t}$$

$$w_t^j = w_{t-1}^j - \frac{n_t}{\sqrt{G_t^j + 10^{-5}}} \cdot h_t^j$$

Упоминание

Оногда в Adam $\frac{\rho}{1-\beta_1^2}$

1 шага

$$h_t = \beta_1 \cdot h_{t-1} + (1-\beta_1) g_t$$

$$\mathbb{E}(h_t) = \mathbb{E}(g_t)$$

$$G_t = \beta_2 G_{t-1} + (1-\beta_2) g_t^2$$

$$\mathbb{E}(G_t) = \mathbb{E}(g_t^2)$$

$$w_t = w_{t-1} - \frac{n_t}{\sqrt{G_t + \epsilon}} h_t$$

$$h_0 = 0$$

$$h_1 = \beta_1 h_0 + (1-\beta_1) g_1 = (1-\beta_1) g_1$$

$$h_2 = \beta_1 h_1 + (1-\beta_1) g_2 = \beta_1 (1-\beta_1) g_1 + (1-\beta_1) g_2$$

$$h_3 = \beta_1 h_2 + (1-\beta_1) g_3 = \beta_1^2 (1-\beta_1) g_1 + \beta_1 (1-\beta_1) g_2 + (1-\beta_1) g_3$$

...

$$h_k = (1-\beta_1) \sum_{i=1}^k \beta_1^{k-i} \cdot g_i$$

$$\mathbb{E}(h_k) = \mathbb{E}\left[(1-\beta_1) \sum_{i=1}^k \beta_1^{k-i} \cdot g_i\right] =$$

$$= (1-\beta_1) \sum_{i=1}^k \beta_1^{k-i} \cdot \mathbb{E}(g_i) = (1-\beta_1) \cdot \mathbb{E}(g_i) \sum_{i=1}^k \beta_1^{k-i} =$$

$$\mathbb{E}(g)$$

с шагом

$$= \mathbb{E}(g_i) \cdot (1-\beta_1) \cdot \frac{1-\beta_1^k}{1-\beta_1} = (1-\beta_1^k) \cdot \mathbb{E}(g_i)$$

Методы второго порядка

Упражнение

$$f(x) = ax^2 + bx + c$$

$$x_t = x_{t-1} - \gamma \cdot \nabla_x f(x_{t-1})$$

$$x^* = -\frac{b}{2a}$$

$$x_0 \quad \nabla_x f(x_0) = 2ax_0 + b$$

$$x^* = x_0 - \gamma(2ax_0 + b)$$

$$-\frac{b}{2a} = x_0 - \gamma(2ax_0 + b)$$

$$\gamma(2ax_0 + b) = x_0 + \frac{b}{2a} = \frac{2ax_0 + b}{2a}$$

$$\gamma = \frac{1}{2a}$$


$$f'(x) = 2ax + b$$

$$f''(x) = 2a$$

$$\gamma = \frac{1}{f''(x)}$$

$$x_t = x_{t-1} - \frac{\eta_t}{f''(x_{t-1})} \cdot f'(x_{t-1})$$

Какое же надо брать, чтобы начать в оптимум за шаг



метод
Ньютона

Линейное приближение

$$f(x) = x^T A x + b^T x + c$$

$$x \in \mathbb{R}^n \quad f: \mathbb{R}^n \rightarrow \mathbb{R} \quad A^T = A \oplus \text{норм. опр.}$$

$$x_t = x_{t-1} - \Gamma \nabla_x f(x_{t-1})$$

Нашим Γ мак, үткөсінің әкесір. Наменде за сәйкес шар

$$df = dx^T \cdot Ax + x^T A dx + b^T dx = (2x^T A + b^T) dx$$

$$\frac{x^T A^T dx}{x^T A dx} \quad \nabla_x f = 2Ax + b = 2Ax + b$$

$$H = \nabla_x^2 f = 2A \quad df = \nabla^T f dx$$

$$x^* = ? \quad 2Ax + b = 0 \quad x^* = -\frac{1}{2} A^{-1} b$$

$$-\frac{1}{2} A^{-1} b = x_0 - \Gamma \cdot (2Ax_0 + b)$$

$$\Gamma(2Ax_0 + b) = x_0 + \frac{1}{2} A^{-1} b$$

$$2A \bullet$$


$$2A \cdot \Gamma(2Ax_0 + b) = (2Ax_0 + b) \quad | \cdot (2Ax_0 + b)^{-1}$$

$$2A \cdot \Gamma = I$$

$$\Gamma = \frac{1}{2} \cdot A^{-1} = H^{-1} = (\nabla_x^2 f)^{-1}$$

$$x_t = x_{t-1} - H^{-1}(x_{t-1}) \cdot \nabla f(x_{t-1})$$

$$f(x') \approx f(x_0) + \nabla^T f(x_0) \cdot (x' - x_0) + \frac{1}{2} (x' - x_0)^T H(x_0) (x' - x_0)$$



$$l(x) = f(x_0) + \nabla^T f(x_0)(x - x_0)$$

Информация

$$f(x) = x^T A x + b^T x + c \quad A^T = A \quad A \succ 0$$

Как обходить:

$$(x_i - x_0) \text{ и } \nabla f(x_i) - \nabla f(x_0)$$

$$x_1 = x_0 - \frac{1}{2} A^{-1} \nabla f(x_0)$$

$$x_1 - x_0 = \frac{1}{2} A^{-1} (0 - \nabla f(x_0))$$

$\nabla f(x_1)$ Т.к. x_1 - ортогональен

$$x_1 - x_0 \approx \gamma \cdot (\nabla f(x_1) - \nabla f(x_0))$$

γ - ? Кто-то работает на синхронизацию

$$y = w \cdot x \quad \text{MSE} \rightarrow \min_w$$

$$\hat{w} = \frac{\sum_i y_i \cdot x_i}{\sum_i x_i^2} = \frac{y^T x}{x^T x}$$

$$\hat{\gamma} = \frac{(x_1 - x_0)^T (\nabla f(x_1) - \nabla f(x_0))}{(\nabla f(x_1) - \nabla f(x_0))^T \cdot (\nabla f(x_1) - \nabla f(x_0))}$$

Англокремагул:

$$x_t = x_{t-1} - \frac{(x_1 - x_0)^T (\nabla f(x_1) - \nabla f(x_0))}{(\nabla f(x_1) - \nabla f(x_0))^T \cdot (\nabla f(x_1) - \nabla f(x_0))} \cdot \nabla f(x_{t-1})$$

$x_1 = x_{t-1}$
 $x_0 = x_{t-2}$

Сходимость градиентного спуска в эпоках
бинарным сдвигом

$$1) f(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

f - L-липшицева в см

$$\forall x \in \mathbb{R}^n \quad \| \nabla f(x) \| \leq L$$

2) f L-нагкад

(∇f - липшицева с конст L)

$$\text{T.e. } \| \nabla^2 f(x) \| \leq L$$


См 2) Тогда $\forall x, y \in \mathbb{R}^n$

$$f(y) = f(x) + \nabla f(x)^T (y-x) + \frac{1}{2} (y-x)^T H (y-x)$$

$$f(y) \leq f(x) + \nabla f(x)^T (y-x) + \frac{L}{2} \|y-x\|^2$$

$$\left\| \frac{1}{2} (y-x)^T H (y-x) \right\| \leq \frac{1}{2} \cdot \|y-x\| \cdot \|H\| \cdot \|y-x\| \leq \frac{L}{2} \|y-x\|^2$$

$$\|x-y\| \leq \|x\| \cdot \|y\|$$



$$x_t = x_{t-1} - \alpha \cdot \nabla f(x_{t-1})$$

$$f(x_t) \leq f(x_{t-1}) + \langle \nabla f(x_{t-1}), x_t - x_{t-1} \rangle + \frac{L}{2} \|x_t - x_{t-1}\|^2$$

$$f(x_t) \leq f(x_{t-1}) - \alpha \langle \nabla f(x_{t-1}), \nabla f(x_{t-1}) \rangle + \frac{L \cdot \alpha^2}{2} \|\nabla f(x_{t-1})\|^2$$

$$f(x_t) \leq f(x_{t-1}) + \left(\frac{\alpha^2 \cdot L}{2} - \alpha \right) \|\nabla f(x_{t-1})\|^2$$

хору селасіб еї маулар болып

$$\frac{L}{2} \alpha^2 - \alpha \rightarrow \min_{\alpha} \quad \alpha^* = \frac{1}{L}$$

$$f(x_t) \leq f(x_{t-1}) - \frac{1}{2L} \|\nabla f(x_{t-1})\|^2$$

$$f(x_{t+1}) - f(x_t) \geq \frac{1}{2} \| \nabla f(x_{t+1}) \|^2$$

Зададено на како да се
докажа близкото

$f(x)$ - близък

$$f(y) \geq f(x) + \nabla^T f(x)(y - x)$$



$$f(x_t) \geq f(x^*) + \nabla^T f(x^*)(x_t - x^*)$$

$$f(x_t) \geq f(x^*)$$

$$f(x_t) - f(x^*) \leq \varepsilon \quad \varepsilon(t) - ?$$

$$f(x_t) - f(x^*) \leq \nabla^T f(x_t) \cdot (x_t - x^*)$$

$$\begin{aligned} f(x_t) &\leq f(x_{t-1}) + \left(\frac{\lambda^2 \cdot L}{2} - \lambda \right) \| \nabla f(x_{t-1}) \|^2 \leq \\ &\leq f(x^*) + \nabla^T f(x_{t-1})(x_{t-1} - x^*) \end{aligned}$$

$$\leq f(x^*) +$$